AAOS 六项核心能力：本次对话完整汇总与开发交接文档

主题： 豆包分析审计｜核心优势判定｜六项能力纠偏｜产品架构｜实施路线｜验收标准
归属： AAOS / ArcheAxis Knowledge / 星环知识平台
版本： 对话整理 V1.0 · 2026-10-10
性质： 对话成果与增量开发建议；**不是新的项目权威文件、发布证明或已经执行的任务回执**

> **最终共识：** AAOS 的双向掌握度、BKT、时序图谱、分层记忆、经验蒸馏与技能演化**存在真实代码及设计基础**；豆包报告的问题主要是把“已实现某个模块”扩大为“已形成成熟产品能力”，把“值得验证的系统组合”写成“全球独有”。六项能力**可以作为核心能力主线**继续完善，但真正的产品优势必须由真实使用、受控验证、版本与效果对照来证明。

第一部分｜本次对话的结论与决议

1. 本次对话依次解决了哪些问题

本次对话围绕以下四个连续问题展开：

1. **豆包的报告是否可信？** 审核其“人机双向学习操作系统”的定位、六项算法、竞品横评、演示方案以及是否存在夸大。
2. **既然确有代码，是否意味着方向正确？** 明确“有实现基础”“设计值得保留”“算法和规则需要修正”“效果仍需验证”四个不同结论。
3. **六项是否构成 AAOS 的核心优势？** 明确它们可以成为**核心能力**，但不能仅凭文件、算法名称、演示图或自身评分断言已拥有竞争优势。
4. **具体怎么开发？** 确定以一个 Rust Core 权威写入链路承接六项逻辑能力，先做双向最小闭环，再联动时序、记忆、经验与技能的长期复测，并设置负向验收用例。

本文将“已看到的代码事实”“对设计的判断”“推荐修正”“应由本地 Agent 再验证的事项”分别表达。正文汇总各轮讨论，第二部分完整保留此前产出的六引擎开发蓝图与 48 项首轮测试用例。

2. 最终判断：属于什么层级的核心优势

结论 A｜核心能力：是。 六项机制能够支撑 AAOS 的长期差异化路线：同一知识既服务人的学习，也服务机器的知识调用与可验证复用，并随证据、经验和任务结果迭代。

结论 B｜原创算法：不宜整体称是。 BKT、FSRS、分层记忆、时间知识图谱、经验规则化及反馈改进各有成熟的研究或产品先例。AAOS 的创新更可能体现为**有边界的组合方式、数据与证据契约、双向用户流程和可靠性**，而不是所有组件由 AAOS 首创。

结论 C｜已经成熟的竞争优势：尚未证实。 需要在正式桌面端证明真实使用、机器调用、知识更新、异常恢复、跨版本一致性，以及对简单基线的增量收益。

结论 D｜工程方向：保留并修正，不推翻重建。 不能因存在明显问题就否定双向学习，也不能只在旧 Python 模块上增加代码而不确认其正式调用资格。

价值主张建议： **“同一份可信知识，人学得更深，AI 用得更准。”** 可继续沿用，但须作为产品愿景与价值主张；对外“已支持”必须按实际测试与安装态证据描述。

3. 豆包总结：哪些应保留，哪些必须改写

豆包主张	审核判断	本次采用的表达或处理方式
AAOS 不只是笔记工具	**基本认可**	改成“不止是笔记工具”；保存、编辑、阅读仍然是第一层用户体验。
六项核心算法，竞品几乎都没有	**明显夸大**	改成“六类重要能力机制”；分别标注代码、接线、验证及效果层级。
人类 M0–M7，机器 K0–K8，可按大小决定谁教谁	**三轴结构有价值，比较规则不成立**	保留等级摘要；按具体任务与能力凭证推荐教学、蒸馏、协作、测量或复核。
BKT 带 EM/隐马尔可夫算法	**源码有依据**	仍需数值测试、参数校准、接入正式学习事件，不能等同于真实学习收益已证明。
时序图谱能还原任意历史事实	**目标合理，现有实现仍有历史查询风险**	区分现实有效时间和系统获知时间，并测试被替代版本历史查询。
L1–L4 是独有分层记忆	**可实现，但并非独有概念**	强化授权、作用域、检索过滤、撤销与原始证据保留。
三案例／80% 一致即可生成专家规则	**有程序阈值，但验证不足**	将阈值视为进入下一步审查的门槛，新增案例独立性、反例和留出任务。
技能补丁全测试通过、回归不超过 5% 即可演化	**部分源码支持，但表述过度完整**	必测指标不能缺失；区分评估、注册、启用、观察与回滚。
每个 AI 回答必须有 EvidenceAnchor，否则拒绝	**与正式普通内容保存原则冲突**	仅对特定专业可信提升／执行用途严格限制；草稿、灵感、假设可先保存。
“全球独一份”“竞品都做不到”	**无充分证据**	删除全球唯一论断，采用可复现实测比较。
做 30 秒 M3/K6 对比演示	**展示直观，但容易误导**	改为“可解释的人的能力、机器资格、证据状态、下一行动”真实案例演示。

竞品横评特别更正： 原表把 Obsidian、Notion、Logseq、RemNote、Anytype 等产品简化为一组“✗”，忽略了插件生态、功能更新与不同系统边界，不能作为权威比较。尤其不能说 Anki／RemNote “只有简单间隔重复”；两者均支持 FSRS。BKT、分层记忆、时间图谱和可复用技能在 pyBKT、MemGPT、Graphiti、Voyager 等项目中均存在相关先例。差异化需比较**完整使用旅程**，不是只比术语。

4. 六项能力的真实代码基础与关键缺口

以下为本次对话中**基于远端固定提交的静态分析结论**。查阅基线：DTALEX66/ArcheAxis-Knowledge-OS，main@4b9828c4058901c0b1fd2c75c528238c55e0ec89。它不是对本机 HEAD、当前运行状态或最新安装包的证明。本次文档整理**没有修改仓库、复跑项目测试或执行三项目联调**。

能力	相关代码	已见的实现基础	必须补核／修正的要点
双向掌握度	app/knowledge/dual_mastery.py	M/K/E 三轴、层级、行动判断、显示序列化	delta = k - h 非同尺度直接比较；bkt_mastery 在人类等级函数中未被使用；部分高等级可由单次布尔证据触发。
贝叶斯知识追踪	app/knowledge/knowledge_tracing.py	BKT 参数、在线更新、序列预测、EM 拟合	update() 的结果含学习转移；校准、真实序列、多学习者隔离、模型与正式学习流程连接需验证。
时序知识图谱	app/memory/temporal_graph.py	有效时间、版本替代、冲突及历史查询相关结构	历史查询按当前 active 状态筛选时可能遗漏已替代旧版本；版本时间不能无条件沿用。
L1–L4 记忆	app/memory/memory_layers.py	四层规则、容量、分类与蒸馏建议	普通非空 tag 不能充当 L4 明确授权；摘要/召回不能成为越权通道；L1 容量只是参数。
人类经验蒸馏	app/knowledge/distillation.py	原则、案例、规则、技能提案；3 案例与 80% 阈值	三条记录未必是独立案例；缺乏反例和外部留出任务时不能升级可信等级。
技能演化	app/knowledge/skill_evolution.py	使用记录、评估、候选补丁、验证、应用接口	benchmark 可缺失；apply_patch() 返回注册载荷不等于已完成发布切换；“无回归”需要有效实测。

补充核查： app/knowledge/co_learning_loop.py 确有双向行动分派逻辑；但分派“需要蒸馏”不等于本次调用已自动完成蒸馏，教学计划也依赖提供实际教学材料。正式 Rust 路径的 crates/archeaxis-api/src/runtime/colearning.rs 已包含机器回答、对应纠正候选与记录路径的代码，仍须验证它与六模块及桌面 UI 的实际贯通情况。

4.1 不可忽略的反例

- **K1 不等于能教人：** 机器仅完成索引时，不可单凭 K 数字大于 M 就获得教学资格。
- **M7 不等于说过一次讲解：** 一条 teaching_evidence=True 的标记不足以说明形成稳定专家能力。
- **BKT 概率不是专家评分：** 后验掌握概率与技能等级、迁移能力、事实真实性分属不同维度。

- **当前被替代，不等于历史无效：** 旧事实今天不活跃，不意味着用户查询过去时不能看到它。
- **有 tag 不代表授权：** 任意普通标签或“我喜欢”句子不能静默进入 L4 长期偏好。
- **三条案例不保证独立：** 重复记录或模型虚构案例不能作为三份真实证据。
- **测试字段存在不代表测试执行：** 缺少必须基准、错误指标方向或未发布读回时不得给出“升级成功”。
- **有证据锚点不保证真实：** 原件锚点、识别忠实度、观点支持、使用资格与人体学习效果必须分开。

5. 从“六项能力”到“实际核心优势”的判断标准

只有当至少三个维度有证据时，才适合将目标从“核心能力”升级为“已证明的竞争优势”：

用户结果： 相同时间、相似任务下，延迟回忆、迁移使用或真实作品／问题解决表现相较简单基线有所改善。

机器结果： 固定模型、工具、任务与预算，增加获准知识、记忆、经验规则和技能演化之后，真正减少重复错误并提高可用质量，不只增加流程复杂度。

可靠性结果： 时间版本可查询、授权作用域不泄漏、错误引用可纠正、任务失败可恢复、技能升级可拒绝或回滚。

不把内部指标当成果： M3→M4、K5→K6、记忆条数或生成技能数量只是中间状态。必须测量用户实际收益与可复现效果。

6. 产品定位、证据治理与三项目边界

6.1 建议保留的定位

对外简版： “同一份可信知识，人学得更深，AI 用得更准。”

说明版： AAOS 是本地优先的人机双向学习与可信知识工作台：能够先保存、阅读、编辑和组织内容，再根据内容与用途连接学习练习、知识依据、AI 资产和实际反馈。

“学习操作系统”可用于远景描述，**不意味着**通用操作系统、通用 Agent Runtime、工作流总调度平台，也不要求实现新的基础模型训练平台。

6.2 必须分清的判断维度

- 内容允许保存，不等于其主张已经核验；没有专业外部证据也不妨碍记录灵感或探索假设。
- OCR／ASR 识别与原件一致，不等于原件中的观点正确。
- 有引用锚点，不等于引用真正支持该结论；引用支持也不意味着任意场景适用。
- 内容被采用，不等于人会了；人会了，不等于 AI 技能可靠可执行。
- AI 能调用技能，不等于通过验证；任务通过一次，不等于长期稳定或可跨模型迁移。
- 某项功能在旧 Python 模块或历史演示中存在，不等于当前正式桌面端已通过安装态验收。

证据 fail-closed 的适用方式： 将严格阻断用于需要严格依据的专业结论提升、受控执行或高风险权限；普通笔记、个人假设、草稿与待核验内容应允许保存。探索性 AI 响应需诚实标记不确定性，不能伪装成已核验结论。

6.3 三项目协作边界（延续现行已整理任务包）

项目	主要责任	在六项能力里的位置
AAOS	知识正文、来源、版本、学习状态、AI 知识资产资格	六项知识与学习机制的权威归属；长期证据与候选处理。
DESIGN-LAB	专业设计判断、设计能力包、视觉表达、课件／动画制作、原生设计产物	从 AAOS 读取获准知识，制作图解、视觉教学、练习素材，回传表达与学习相关候选反馈。
WORK-LAB	工作流、编程实践、执行环境、技术复现、AI 治理实践	贡献真实使用回执、失败经验、复测环境与技术候选；不替代 AAOS 知识单写者。

三个仓库**不合仓、不共享业务数据库**；通过版本化、带来源与权限的受控交换连接。相同人或同一模型多次自评，不能声称形成独立三方审计。跨项目知识纠正须经过相应责任方和授权，不暗中覆盖原始记录。

6.4 与此前任务包的关系

本次会话属于 **2026-10-09 AAOS 综合任务包与 UI 任务包的增量补充**：深化双向掌握、BKT、时序知识、记忆、蒸馏、技能演化的技术与验收定义，而不是替代原有 CAP 编号、正式 AAOS-01 活动队列、系统母定义或另建第七套权威文件。实际有效条款应被本地执行器映射入现有相应规范、台账、能力目录和测试。

现行技术方向为 **React／TypeScript／Vite + Tauri 2 + Rust Core 单一业务写入者 + SQLite/CAS + 隔离 Python workers**。正式写入和版本控制走 Core；worker 完成计算、模型调用或候选生成，不直接写权威业务库。知识图谱、全文/向量与记忆索引是可重建投影；不需要六套微服务。

7. 推荐的真实演示：不再讲“AI 比你高三级”

原豆包的“30 秒 M3/K6，给你三道题”有记忆点，但**等级不同量纲，学习效果未经验证**。建议用一个可复现的知识节点演示真实流程，例如“视觉层级”“版式主次”或“某个开发环境常见错误”。

演示 A：人类学习。 显示“已经能够解释、陌生应用还未测试”；提供一项对应练习；记录真实答题、提示使用及反馈；解释能力状态变化来源。

演示 B：人教系统。 展示一次 AI 的不理想结果及用户修改；生成附有条件和反例的经验候选；在新的任务中验证，形成有限用途技能，而不是自动宣布“AI 学会专家经验”。

演示 C：知识变化。 更新一个来源版本，仍可查历史状态；提示受影响课程和技能；保留历史学习记录，并让必要的机器能力进入复测状态。

三项目联合演示（非首轮强依赖）： AAOS 管理知识与学习目标；DESIGN-LAB 产出图解、动画或课件；WORK-LAB 贡献真实环境执行与技术纠错；回传的反馈由各自责任方判断并提请修订。展示真实交换回执，而非只录 UI 跳转视频。

8. 开发优先级：先闭环，不把六项重写成六个独立后台

建议阶段	主要事项	完成声明需要什么
0｜现场和依赖对账	核对本地 HEAD／dirty／worktree；分辨正式调用、可复用算法、历史模块、已被替代代码。	有明确的调用链与代码／数据／测试证据。
1｜写回基础	复用 ID、版本、事件、授权、幂等、冲突及恢复契约；缺什么补什么。	普通内容可保存，重试不双写，重启能读回。
2｜人的最小闭环	真实学习观察→BKT／能力状态→下一行动建议→UI 读回。	每个建议可解释，未测不冒充已掌握。
3｜机器的最小闭环	真实纠错→经验候选→范围验证→技能提案→调用／回滚。	真实独立任务证明有用，未测不激活。
4｜六项联动	双时间知识、记忆许可、来源变化影响课程／技能、失效复测。	历史查询正确，权限与修订不漂移。
5｜产品和收益验证	正式桌面、安装态、备份恢复、长期对照试验。	工程正确与学习／机器增益分别报告。

阶段 2 与 3 必须相邻推进，防止 AAOS 退化为“只有复习”或“只有 AI 技能管理”。每阶段**先复用合格现有组件**，不得只因为名称不匹配就重建。

9. 本次对话统一确立的禁止误判与实施红线

1. 不以“有代码、测试文件、22 张页面效果图、CI 数量”替代正式桌面使用与安装态验收。
2. 不用 M/K 数字直接比较人和 AI 的智慧、知识真实性或专业水平；M 等级、K 资产成熟度、机器任务能力凭证、证据状态必须分开。
3. 不把 BKT 后验、FSRS 复习概率、Teach-back 评分加为一个统一的“掌握准确率”。
4. 不让时序图谱投影成为第二权威数据库；不把今天的状态套回历史任意时点。
5. 不让重复案例、模型虚构案例或自评形成独立证据；保留反例与来源共同谱系。
6. 不允许工作流或模型私自提升 L4 长期偏好、改变用户权限或跨项目复制私有内容。
7. 不把技能 approved、patch applied 或仓库里存在新文件等同于真实注册、启用、复测与回滚成功。
8. 不把“不通过严格证据门槛”扩大为“不允许普通内容保存”。
9. 不直接改 WORK-LAB、DESIGN-LAB 私有数据库；外部交换是版本化、获准、可撤回的最小材料。
10. 不把本次总结或开发蓝图当成新的项目真值源；历史可查，执行按实际当前权威。

10. 文档状态与交接提示

本轮已完成： 汇总本次对话的审计结论、方向判断、六能力逻辑结构、实现修正重点、增量开发顺序和验收设计，并将原开发蓝图全文附在下文，便于本地 Agent 拆分切片。

本轮没有完成： 对本机最新工作树的扫描、六项模块的运行级验证、正式 UI 联调、三项目联合测试、基准对照实验、安装态与长期用户效果验收。不得将以下建议的阶段、测试 ID 或接口名称当作现成 API／已通过结果。

行动要求： 本地 Agent 先读取当下 AGENTS.md、AUTHORITY.md、PROJECT_CONTRACT.yaml、活动任务包和唯一当前台账，然后将此文档逐条映射到已有 CAP、Q、F、接口、状态与测试。只修正能证实的偏差并报告剩余缺口；不能整包重跑历史任务或创造另一套 current。

第二部分｜六项核心能力完整开发蓝图（保留此前任务文档）

以下保留本次对话已经形成的实施细则与原有 48 条验收用例，作为落地补充材料。其编号、接口示例、任务阶段为设计建议，**不自动提升仓库中任何任务状态**。

1. 定位结论

六项能力适合作为 AAOS 的核心能力主线，但不应宣称为六个原创大模型。核心产品价值在于：同一份知识连接人的学习表现、机器侧可验证的使用能力、来源与版本、获准记忆、经验提炼及技能改进。

“核心能力”与“已证明的竞争优势”分开登记。模块存在、单元测试通过、正式桌面流程可用、长期有效、优于对照产品，是不同层级的结论。

能力	工程性质	初期是否需要大模型参数训练
双向掌握度	任务能力证据模型与行动策略	不需要
BKT	小型概率模型；可拟合少量参数	不需要基础大模型训练
时序知识图谱	版本、双时间查询、关系投影	不需要；语义抽取可调用已有模型
L1–L4 记忆	作用域、授权、召回和生命周期策略	不需要；摘要可调用已有模型
人类经验蒸馏	经验抽取、条件化规则、案例验证	不需要；调用已有模型生成候选
技能演化	使用评估、候选修改、对照试验与版本切换	不需要；后续训练另行论证

2. 不改变的工程边界

沿用现有 React/TypeScript/Tauri → 有限宿主接口 → Rust Core → SQLite/CAS 的正式路径。Python workers 只计算或生成候选，不直接写权威数据库。项目合同已经禁止 UI、worker、agent 直接 SQL 和双写。[R1]

普通保存不等待外部证据、云端服务或人工审核。来源核验、专业支持分析、内容采用、学习测量和执行许可分别记录。严格限制针对相应的可信提升或高风险执行，不针对一切草稿和探索。

不因本蓝图新增六个微服务、六套数据库、第二个知识主库、完整事件溯源平台或图数据库。现行合同明确将图数据库和 full event sourcing 等列为阶段外事项。[R1]

六个引擎是逻辑边界，不是强制部署边界。复用现有来源、版本、学习事件、候选、技能、验证回执、备份和恢复设施。先查调用链，再判断代码是正式实现、可吸收计算模块、历史行为参考还是已被替代。

三项目独立仓库、独立业务数据库。AAOS 管本系统知识、学习状态与资产资格；WORK-LAB 负责其执行、技术复现和客户端适配；DESIGN-LAB 负责专业设计判断、表达与教学材料制作。跨项目通过已获准的版本化接口交换最小必要材料，不直接读写彼此数据库，不把 AAOS 六引擎建设变成强制接管另外两项目的运行时。

3. 先统一对象、版本和可追溯写回

以下是逻辑对象，必须优先映射已有 schema，而不是按名称机械新建表。

对象	必要语义
KnowledgeRevision	知识标识、版本、内容哈希、来源、作用域
EvidenceReference	原件/版本/位置、支持或反对关系、核验方式与状态
LearningObservation	人、知识版本、任务、原始回答、评分依据、提示使用、事件时间
HumanCapabilityState	各任务维度的证据状态、估计来源、测量时间、规则版本
MachineCompetenceReceipt	知识版本、技能版本、执行配置、任务范围、测试集、指标、局限
MemoryProjection	所属层、原内容引用、授权、作用域、有效期、派生关系
PrincipleCandidate	条件、行动、例外、支持案例、反例、状态
SkillRevision	父版本、输入输出、允许用途、权限、依赖和内容哈希
EvaluationReceipt	被测对象哈希、评估配置、测试材料版本、执行记录和结果

通用要求：

- unknown / not_assessed / insufficient_data / failed / not_applicable 分开，不能全部转换为零分。
- observed_at 与写入时间分开；统一时区和时间解析，不用格式不一致的字符串直接比较。
- 写入携带幂等键、预期版本和来源；同一事件重试不能产生第二次学习、第二个独立案例或第二次发布。
- 自动评分必须保留评分器版本、评分标准与原答案。AI 生成的解释不能自称独立的人工确认。
- worker 基于快照计算；Core 校验回传内容、权限与预期版本后，在同一事务中保存结果及必要的本地变更记录。并发冲突返回明确状态，不覆盖别人更新。
- 长任务开始、成功、失败、取消分开；失败不得转成已完成。重启后能够读回已提交状态。

这些要求不等于引入“全系统事件溯源”。允许在现有表上采用事务、版本记录与可重建投影。

4. 引擎一：双向掌握度与行动建议

4.1 目标

回答“这个人在当前任务上会什么”“当前系统配置能可靠做什么”“知识依据有何限制”“下一步有哪些合适动作”，而不是判断人和 AI 谁的等级数字更大。

现有 app/knowledge/dual_mastery.py 直接比较 M/K 索引；bkt_mastery 字段没有参与人类等级函数。应保留接口兼容信息，修正决策语义，不把旧数字差值继续传播到正式 UI。[R2]

4.2 第一版实现

人的状态采用任务维度：回忆、解释、解决、迁移、创造、教学。每项记录未测、初步表现、重复验证、待复测等语义，并引用真实任务结果。M0–M7 可以保留为可解释的摘要，不作为唯一真相，也不能把一次“讲解成功”自动等同于专家。

机器侧拆成两部分：K0–K8 表达知识资产的加工/复用成熟度；MachineCompetenceReceipt 表达某个执行配置在指定任务上的实测能力。收到文件、建立索引或创建技能，均不等于获得教学或执行资格。

机器能力至少绑定：知识版本、技能版本、模型/提示词/工具配置指纹、任务范围、测试集版本、评估时间。更换模型后允许复用资产，但不无条件继承旧验证结论。

证据侧底层至少分开：核验状态、时间适用性、争议状态、采用/使用范围。UI 可以显示摘要，但不能因为内容“较新”就抹去争议。

建议输出是有顺序的行动列表，而不是必须五选一的互斥动作：教学、能力测量、经验提炼、协作、材料补充、证据复核都可以带理由返回。普通保存与探索不进入严格证据阻塞流程。

逻辑接口示意，非已存在的命令名称：

```
assess_human(observations, rubric_version) -> human_state
assess_machine(receipts, task, execution_profile) -> machine_state
recommend_actions(goal, human_state, machine_state, evidence, policy)
  -> [{action, reason, evidence_refs, scope, limitations, consent_required}]
```

4.3 首轮验收用例

ID	必须覆盖的情况	期望
DUAL-01	无学习记录	显示未测，不伪造低能力结论
DUAL-02	只有 K1 索引	不自动获得教学资格
DUAL-03	通过一次复述	不直接成为专家
DUAL-04	人与机器各有互补能力、等级不相等	仍能建议协作
DUAL-05	只有特定检查任务通过	不外推为整个领域已验证

ID	必须覆盖的情况	期望
DUAL-06	知识依据存在争议	保留争议，不阻止普通保存
DUAL-07	更换执行模型或工具版本	保留资产，相关能力待复测
DUAL-08	查看任一等级或建议	能解释依据、版本与适用范围

5. 引擎二：BKT、复习与任务测量

5.1 目标

BKT 用来估计某个可定义技能的潜在掌握状态、预测后续回答。它不是专家分数，不等于记忆调度，也不自动证明迁移与创造能力。pyBKT 提供模型拟合、预测和验证的现成参考。[R4]

5.2 数据先于训练

先定义少量可评估的知识技能与题目映射。一个回答可能涉及多个能力，但第一版应优先采用主技能清晰的任务，避免把一题总分重复当作多个独立知识点的正确证据。

观察至少包含：学习者、知识版本、题目/任务版本、原回答、正确性或分项评分、提示使用、评分器、发生时间、会话/尝试标识。创作、美感和复杂设计表现优先用分项评估标准，不能硬塞进二值 BKT。

参数表示：L0 初始概率、T 学习转移概率、G 未掌握时猜对概率、S 掌握时答错概率。对于答对：

$$\text{posterior_after_answer} = p*(1-S) / [p*(1-S) + (1-p)*G]$$
$$\text{next_prior} = \text{posterior_after_answer} + (1-\text{posterior_after_answer})*T$$

答错时使用相应的错误似然。记录“观察后的后验”和“学习转移后的下一步先验”的不同语义；现有 update 的返回值包含转移，不要把名字误当成严格的观察后验。[R3]

5.3 分阶段实现

第一版保留当前纯计算实现，建立手算/参考实现对照和边界测试，以版本化默认参数运行。没有足够观察时显示“基于默认先验，尚未校准”，不捏造个人训练结论。

第二版才做 EM 拟合。按学习者、技能和时间保存序列，不能把不同人的答题随意拼接。个人数据不足时先使用共享或领域先验；个性化不是强行给每个知识点拟合四个不稳定参数。参数优化在后台作业中执行，而不是每回答一次都训练。

评估以时间外推或学习者分组的留出数据进行；同时比较默认 BKT、拟合 BKT 和简单历史正确率基线。报告 Log Loss、Brier score/校准和样本量；不能只报训练集正确率。小样本不足以定论时维持旧参数。

BKT 与 FSRS 共用原始观察，但输出分开：BKT 辅助技能状态推断；FSRS 输出复习时机和回忆概率。复述、迁移、创造采用任务证据。不得相加 BKT 与 FSRS 的概率，或把同一次回答重复计算为两次独立能力证据。FSRS 优先复用项目已吸收、锁定版本的实现。[R5]

5.4 首轮验收用例

ID	必须覆盖的情况	期望
BKT-01	手算答对/答错序列	与参考公式在约定数值容差内一致
BKT-02	同一回答重试上传	只更新一次
BKT-03	缺失答案、取消或无法判分	不当作答错
BKT-04	使用提示后答对	保留提示条件，不冒充独立作答
BKT-05	NaN、无穷、越界参数、退化观测	明确拒绝/标记异常，不输出伪概率
BKT-06	只有少量个人数据	不强制宣称个性化训练有效
BKT-07	断开云端并重启	已有记录与本地调度可恢复
BKT-08	看过训练用题后的相似题	与真正的留出迁移测试分开报告

6. 引擎三：时序知识图谱

6.1 目标与存储

在既有知识版本、来源和 SQLite 关系上建立可重建的图谱投影；不是建立第二个知识数据库。Graphiti 的时间语义可作为参考，不意味着必须整体引入其服务和存储依赖。[R6]

底层区分：实体、声明、来源版本、证据关系、声明适用范围和版本修订。声明不是无条件事实；来源更新也不自动使旧声明错误。

6.2 双时间

需要分别表示现实适用时间与系统已知时间。逻辑字段可为：

valid_from / valid_to 现实适用区间
recorded_from / recorded_to 系统记录这一版本断言的区间

查询接受 valid_at 与 known_at。采用半开区间并统一 UTC 解析。空的起止时间明确表示未知或无界，不能混淆。

例：某规则 3 月 1 日生效，系统 3 月 10 日才录入。回看“3 月 5 日实际适用什么”和“截至 3 月 5 日系统知道什么”是两种问题。后录入的信息不能泄漏到更早的“当时已知”查询里。

旧记录今天被替代，不代表它在过去的适用时点应被过滤掉。新版本也不能无条件继承旧版本的有效起始时间。更正历史断言时保留前一系统记录版本，不能只覆盖一行而丢失 known-at 语义。

6.3 冲突与影响

先按实体、谓词、作用域、条件和重叠时间筛选候选关系，再做规则或语义比较。AI 可以提出冲突候选，但不能把“新内容出现”直接等同于“旧内容已失效”。专业声明的替代依据和采用策略必须可追溯。

来源或规则更新后，计算受影响的引用、学习材料和技能。对机器标记相关资格待复测；对人提示更新差异和相关复习，不删除已经发生的学习记录，也不推断人瞬间失去全部能力。

6.4 首轮验收用例

ID	必须覆盖的情况	期望
TIME-01	今天已 superseded 的旧版本	历史有效时点仍可正确查询
TIME-02	信息晚于实际生效时间录入	valid-at 与 known-at 给出正确差异
TIME-03	相同主体、不同使用范围的声明	不误判为直接矛盾
TIME-04	声明存在真正重叠冲突	两边来源与条件均保留
TIME-05	仅文档编辑时间变新	不自动提高内容可信度
TIME-06	来源更新使某规则待复核	能定位受影响技能与教学材料
TIME-07	时区、边界时刻与空时间	结果符合约定的区间语义
TIME-08	重新构建图谱投影	不丢原件、版本或引用身份

7. 引擎四：L1–L4 分层记忆

7.1 目标

记忆是“哪些信息可以在当前任务中被调用”的机制，不是越多越好，也不是第二份权威知识。分层上下文管理可参考 MemGPT，但 AAOS 的分层策略与隐私授权须独立实现。[R7]

层	建议语义	初期实现
L1	当前任务上下文	受 token/容量限制的活动窗口，必要信息可固定
L2	项目作用域上下文	引用项目材料与获准回执，不跨仓直读业务数据库
L3	可复用领域知识	从获准知识与技能生成的可重建投影
L4	用户明确认可的偏好/习惯	带目的、作用域、授权、撤销记录

7.2 检索与写入

检索先做身份、作用域、授权与用途过滤，再排序；不得让高相关性得分覆盖硬权限。严格用途与探索用途使用不同的资格策略，未验证内容可以在获准探索中被明显标记地使用。

先建立全文检索基线，再根据实测决定是否增加向量召回与重排序。记忆结果应返回原始引用、版本、进入上下文的原因和使用限制，而不只是摘要。

L1 的“50 条”只能是可调的工程参数。活动窗口淘汰不等于删除原始材料；长文本应结合 token 预算处理。向 L3/L4 提升必须有相应采用或授权依据，不能因为提及次数多就自动成为专业规则或长期人格。

L4 需要明确的偏好授权标识及真实授权记录，任意非空 tag 不够。引述他人说“我喜欢……”也不能变成用户偏好。用户撤销时，停止召回并处理索引、摘要和派生缓存；日志保留与原件删除按既有策略区分，不借 append-only 忽略撤销。

检索材料中的“指令”按内容处理，不能自行更改系统权限或启动执行。

7.3 首轮验收用例

ID	必须覆盖的情况	期望
MEM-01	项目 A 请求项目 B 私有内容	在召回和模型输入前阻断
MEM-02	普通 tag + “我喜欢”	不自动获得 L4 授权
MEM-03	引用他人的偏好	不记成用户本人偏好
MEM-04	撤销某条偏好	后续召回及派生缓存不继续使用
MEM-05	L1 超容量	活动窗口缩减，但原内容不丢失
MEM-06	多次重复同一经验	不自动成为 L3 已验证规则
MEM-07	过时来源、严格任务	依用途策略处理并显示限制
MEM-08	记忆文本含恶意执行指令	不提升权限、不触发工具执行

8. 引擎五：人类经验蒸馏

8.1 目标

把人的判断转为有条件、有反例、可测试的经验资产。这里的“蒸馏”首先是知识表达与验证，不是神经网络知识蒸馏或基础模型微调。

输入优先来自真实任务中的纠错：原输出、用户修改、修改理由、任务背景、前后结果和不适用条件。普通笔记与单个案例可以保存为候选，不能因为尚未构成规则就拒绝接收。

8.2 候选结构

principle_id
statement
applicable_when
recommended_action
exceptions
supporting_case_refs
counterexample_refs
source_and_owner
allowed_uses

evaluation_status
revision

AI 可以抽取候选、追问遗漏条件、组织正反案例，但不能把个人风格喜好自动宣称为普遍设计规律，也不能把生成的虚构案例登记成真实独立证据。

现有“三案例、80%一致”最多先作为进入进一步审核的默认条件，不作为普遍可靠性的证明。按真实任务、来源、素材或情境聚类，避免把同一案例的多个描述计算成独立支持。记录反例而非删去反例提高比例。

建议流程：候选原则 → 补充条件与反例 → 独立案例核查 → 保留案例测试 → 限定范围试用 → 形成规则/技能提案。具体状态名映射现有 schema，不另造第二套权威状态机。

生成技能提案时明确输入输出、允许与禁止任务、依赖、权限、来源及适用范围。教学材料与可执行技能分别出包；二者都不自动激活。

8.3 首轮验收用例

ID	必须覆盖的情况	期望
DIST-01	单个真实案例	可保存，但不宣称已验证规律
DIST-02	同一案例复制三次	不计为三个独立支持
DIST-03	有明确反例	保留并调整条件/范围
DIST-04	个人审美偏好	保持偏好身份，不自动成为事实
DIST-05	AI 生成的合成案例	标为合成，不冒充真实观测
DIST-06	留出任务验证失败	不晋升相应使用范围
DIST-07	原因说明被用户纠正	形成新版本，不覆盖原记录
DIST-08	从规则生成技能	仍是待验证/待获准候选

9. 引擎六：技能演化

9.1 目标

基于真实失败和效果改善技能资产，而不是允许 AI 无限制修改自身、系统约束或基准。Voyager 提供“可复用技能库 + 执行反馈改进、不必微调基础模型”的研究先例，但其结果不能直接作为 AAOS 的效果证明。[R8]

9.2 首先记录可归因的使用结果

每次使用记录：任务及其版本、技能版本、模型/工具/环境配置、知识与记忆引用、输入输出、执行结果、质量测量、人工纠正、成本和耗时。明确哪些指标未测。

失败先区分知识过时、规则不完整、提示词问题、工具变化、网络/环境故障与评分不确定。网络失败不能直接作为“技能差”的证据；未完成执行也不能冒充质量评测失败或成功。

9.3 修改与评估

初期一次补丁只解决清楚的问题。补丁生成在候选分支或候选资产中发生；不能直接写当前激活版本。测试集、评分规则、权限和判定阈值不允许由待评估技能自行改动。

评估分开发集、独立保留任务与不可退步的安全/边界案例。记录生成模型与评分器来源；同一模型自评不是独立实证。需要时用人工抽检或实际可执行检查补充。反复试错会消耗留出集的独立性，因此轮换保留材料、保留未见任务。

每项指标声明方向、单位、基准、容忍度及是否必需。不能对成功率、成本、耗时套同一个“5%”规则。必需指标缺失、NaN 或无法执行时，结论是未完成/不可判定，不是通过。成本或速度的改善不能掩盖安全或关键质量失败。

随机生成任务用成对的相同任务比较候选与基线，做必要重复并报告差异不确定性。低风险用途可以在用户预先批准的范围中自动化验证与试用；高风险启用保留人工批准。

9.4 发布和回滚

完整链条：候选补丁 → 固定版本测试 → 评估回执 → 用途批准 → Core 原子注册新版本并切换有效指针 → 实际调用读回 → 监测 → 必要时切回旧版本。

版本切换校验被测载荷哈希、依赖与预期当前版本，防止测的是 A、用的是 B。重启后有效版本一致。回滚技能版本不自动撤销已经发生的外部副作用，外部执行需另有补偿或人工处理方案。

更换模型或软件后，资产可以迁移，但对应任务要做兼容复测；“可移植”不等于“跨模型效果完全一样”。

9.5 首轮验收用例

ID	必须覆盖的情况	期望
EVOL-01	未测任务/缺少必需指标	不返回已通过
EVOL-02	成本下降但关键质量下降	按预定义策略拒绝或保留旧版本
EVOL-03	候选试图修改基准或评分器	阻断并记录
EVOL-04	测试后载荷发生变化	哈希不一致，不能启用
EVOL-05	并发发布到同一技能	预期版本冲突不丢失更新
EVOL-06	切换过程中故障并重启	活跃指针与注册状态保持一致
EVOL-07	高风险技能自动请求启用	不越过所需批准
EVOL-08	回滚并真实调用	使用旧版本，说明外部副作用边界

10. 开发顺序与阶段产物

这些是建议的增量切片；先映射当前任务，不创建另一份自称 current 的排期。

阶段	工作	通过条件
0 对账	当前权威、正式调用链、既有对象、旧模块位置、测试与开源吸收状态	每项有复用/修复/迁移/后置判断，不能仅按目录名判断完成
1 共用基础	版本、观察、回执、授权和受控写回的最小补齐	重试、并发、重启、恢复与普通保存均有实际测试
2 人类最小闭环	三轴任务状态 + BKT + 既有复习 + 基本证据引用	用户作答→更新→下一步建议→重启后续用
3 机器最小闭环	纠错→经验候选→独立验证→技能试用→新任务评估	新任务实测、引用可追溯、可拒绝与可回滚
4 六项联动	双时间、作用域记忆、更新影响、技能资格复测	来源变化能准确影响后续教学/使用，但不破坏历史记录
5 产品与效果	真实桌面入口、导出/恢复、对照试验	工程通过与收益证明分开报告

不把人的学习推迟到“先完成所有机器能力后”，也不把机器经验学习推迟到只有复习工具。阶段 2、3 是紧邻的双向最小闭环；第一轮可限定极少知识与任务，后续扩展覆盖面。

11. 统一 UI，而不是六个孤立后台

建议承接于四种工作界面：知识详情中的能力与依据区、学习工作区、经验与技能区、来源/版本时间线。记忆授权和“为什么召回此内容”用抽屉或设置承接，不强迫普通用户学习六套后台术语。

每个状态能打开原始依据；每个自动建议显示原因与限制；每个未完成任务显示可重试的真实状态。M/K 编码属于高级展开信息，普通界面优先表达“已能解释”“陌生场景待验证”“当前工具配置已通过哪些任务”。

12. 怎样证明它成为核心优势

工程正确性与业务效果分开评估。

人的收益：比较同等学习时间下的延迟回忆、陌生情境应用与真实作品/任务表现；不以系统自报的 M 等级上升作为唯一成功指标。单用户项目可先做匹配知识点、多轮小规模交替对照，不能由一轮展示外推长期效果。

机器收益：同一模型、同一工具、同一任务预算，比较基础检索、加获准记忆、加经验规则、加演化技能。报告成功率、重复错误率、依据使用错误、成本与耗时。逐项加入能力，检查复杂度是否产生真实增益。

可靠性收益：历史时点查询准确性、错误冲突率、失效知识误用率、权限泄漏测试、恢复成功与回滚完整性。测试集上的零泄漏是该测试集的结果，不是对所有未来场景的绝对保证。

如果某个新算法暂未胜过简单基线，保留结果和研究目标，在产品中继续用更稳妥的基线，而不是硬上线或删除长期能力定位。

13. 首轮本地 Agent 执行指令

你正在 AAOS 仓库内执行增量开发分析。先读取根 AGENTS、AUTHORITY、现行项目合同、当前任务与替代决策，并记录本地分支、HEAD 和未提交状态。

本轮目标是把双向掌握度、BKT、时序知识图谱、L1-L4 记忆、人类经验蒸馏、技能演化映射到当前正式产品路径，不是重写六个新模块。

先只读核对：逐项输出真实入口、调用者、输入输出 schema、权威写入者、现有测试、当前桌面入口与剩余缺口。远端分析基线不覆盖本地更新。旧 Python 模块按正式实现/可复用计算/行为参考/已替代分别标记。

优先选一个范围最小且当前任务允许的切片：一次真实学习观察，经现有 Core 受控写回，更新 BKT 估计和任务能力依据，并在知识详情里解释下一步建议。M 与 K 不能直接相减；未知状态不能伪造为零分；没有外部证据不阻塞普通保存。

随后规划紧邻的机器侧切片：一次真实纠错形成经验候选，在独立任务验证后产生限定用途技能提案，并证明真实调用与回滚。

不得新增知识主库、worker 直接 SQL、跨项目共享业务 DB、六套微服务、完整事件溯源平台，或暗中修改项目权限/当前任务权威。需要更新规范时先说明被替代条款和兼容影响，在既有授权与变更流程内办理。

获准实现的每个切片必须提交：最小代码变更、对应反例测试、实际命令与退出结果、版本/重启读回证据，以及已验证/未验证/未运行状态。不得以截图、模块文件存在、测试数量或 AI 自评代替完成结论。

14. 资料依据与使用范围

[R1] AAOS PROJECT_CONTRACT.yaml，固定提交；用于约束架构、普通保存和阶段外范围。
https://github.com/DTALEX66/ArcheAxis-Knowledge-OS/blob/4b9828c4058901c0b1fd2c75c528238c55e0ec89/PROJECT_CONTRACT.yaml

[R2] AAOS dual_mastery.py，固定提交；用于判断现有三轴及索引差值规则。
https://github.com/DTALEX66/ArcheAxis-Knowledge-OS/blob/4b9828c4058901c0b1fd2c75c528238c55e0ec89/app/knowledge/dual_mastery.py

[R3] AAOS knowledge_tracing.py，固定提交；用于判断现有 BKT 在线更新和 EM 结构。
https://github.com/DTALEX66/ArcheAxis-Knowledge-OS/blob/4b9828c4058901c0b1fd2c75c528238c55e0ec89/app/knowledge/knowledge_tracing.py

[R4] pyBKT 官方项目，模型拟合、预测、交叉验证与参数约束参考。
https://github.com/CAHLR/pyBKT

[R5] Py-FSRS 官方项目与文档，复习调度、日志和状态序列化参考；正式接入须使用仓库锁定版本。
https://github.com/open-spaced-repetition/py-fsrs
https://open-spaced-repetition.github.io/py-fsrs/

[R6] Graphiti 官方项目与介绍，时序关系和系统获知时间的参考，不是整体引入依赖的指令。
https://github.com/getzep/graphiti
https://www.getzep.com/platform/graphiti/

[R7] MemGPT: Towards LLMs as Operating Systems，分层上下文管理研究参考。
https://arxiv.org/abs/2310.08560

[R8] Voyager: An Open-Ended Embodied Agent with Large Language Models，可复用技能库和反馈改进研究参考。
https://arxiv.org/abs/2305.16291

文中接口、测试 ID、阶段划分与产品建议均为本次设计提案，不冒充上述来源已有的 API、实验结论或仓库已完成能力。外部项目仅作相关机制参考；引入代码、模型或新依赖之前仍需按项目现行吸收与许可流程核对版本及适用条件。

第三部分｜材料定位与版本依据

用户提供的起点： 本次对话内的豆包《AAOS 核心优势分析》全文；其中同类竞品能力打叉、M/K 等级示例、算法成熟性和全球独有等内容作为“受审观点”保留，不作为事实权威。

本次对话前序输出： 已完成三轮判断——“真实但被夸大”“值得继续完善，但不等于规则都正确”“六项适合作为核心能力主线，并已给出详细开发蓝图”。本文将三轮的结论、约束和实施建议合并，而不是将原豆包文案照单全收。

项目协作来源： 2026-10-09 AAOS 综合任务包、AAOS UI 前端任务包与 DESIGN-LAB／WORK-LAB 协作约定；这些材料要求三仓独立、知识侧由 AAOS 承接、正式 UI 与能力目录归现行权威维护。

远端源码核对快照： 固定提交 4b9828c4058901c0b1fd2c75c528238c55e0ec89（并不代表本地最新状态）。需要在本地重新确认 HEAD、dirty、测试、架构映射与运行环境。

边界提醒： 本整理是“对话成果存档＋执行输入”，而不是新设的母定义或直接变更授权。归档旧记录时要保留原字节和原日期，针对活跃消费者修改有效索引与生成源，不得因文档日期较旧就删除仍有效的能力。